



DISTRIBUIÇÕES AMOSTRAIS



Distribuições Amostrais

- A população define um conjunto vasto, em geral, impossível de conhecer.
- A amostra constitui um subconjunto da população.
- Uma amostra aleatória é uma amostra em que a probabilidade de cada elemento ser seleccionado é conhecida.
- O objectivo é, a partir da amostra, estabelecer conclusões para o todo representado pela população.



Definições

- Amostra aleatória x_1, x_2, \dots, x_n
- Uma **estatística** é uma medida numérica calculada a partir dos dados amostrais.
- Um **parâmetro** é uma medida numérica de uma população.



Definições

	População	Amostra
Média	μ	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
Desvio Padrão	σ	$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$
Variância	σ^2	$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$



Definições

- **Estatística Inferencial** é o conjunto de procedimentos que permitem, a partir de uma amostra, fazer inferências para a população.
- Se x_1, x_2, \dots, x_n são variáveis aleatórias independentes e identicamente distribuídas, então constituem uma **Amostra Aleatória** de uma população infinita caracterizada pela sua distribuição comum.



Definição

- Se x_1, x_2, \dots, x_n constituem uma **amostra aleatória**, então

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

é a **média amostral** e,

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

é a **variância amostral**.

- As **estatísticas** são funções de variáveis aleatórias.

Distribuição da Média

Se x_1, x_2, \dots, x_n constituem uma amostra aleatória de uma população infinita com média e variância então

$$E[\bar{x}] = \mu$$

$$Var[\bar{x}] = \frac{\sigma^2}{n}$$

$$E[\bar{x}] = E\left[\frac{\sum_i x_i}{n}\right] = \frac{1}{n}(n\mu) = \mu$$

$$Var[\bar{x}] = V\left[\frac{\sum_i x_i}{n}\right] = \frac{1}{n^2}(n\sigma^2) = \frac{\sigma^2}{n}$$



Teorema do Limite Central


Se x_1, x_2, \dots, x_n constituem uma amostra aleatória de uma população com média μ e variância σ^2 finita, a distribuição limite de

$$z = \frac{\bar{x} - \mu}{\sigma / \sqrt{n}}$$


à medida que $n \rightarrow \infty$ é a distribuição normal padrão.




Amostras Aleatórias (N=10 000)



UNI




NORM




EXP




Amostras Aleatórias (N=2 000)



UNI_5




NORM_5




EXP_5




Amostras Aleatórias (N=500)



UNI_20



NORM_20



EXP_20



Distribuições Amostrais

Exemplo 8

Suponha que as classificações, a nível nacional, do exame de Geografia, têm uma média de 14.3, com um desvio padrão 2.1. Assumindo que a distribuição é normal, calcule:

- a) a probabilidade de que um estudante, seleccionado aleatoriamente, tenha uma classificação superior a 16 valores.
- b) a probabilidade de que uma amostra aleatória de 10 estudantes tenha uma média superior a 16 valores.

a)

$$P(x > 16) = P\left(z > \frac{16 - 14.3}{2.1}\right) = P(z > 0.81) = 0.2090$$


b)

$$P(\bar{x} > 16) = P\left(z > \frac{16 - 14.3}{2.1/\sqrt{10}}\right) = P(z > 2.56) = 0.0052$$



Distribuições Amostrais

Exemplo 8





Distribuições Amostrais

Exemplo 9

Uma máquina de enchimento de açúcar está regulada por forma a que a quantidade em cada pacote seja de 1000 gramas, com um desvio padrão de 50 gramas.

Qual a probabilidade de que a média de uma amostra de 36 pacotes seja menor que 980 gramas?

$$\mu_{\bar{x}} = \mu_x = 1000$$

$$\sigma_{\bar{x}} = \sigma_x / \sqrt{n} = \frac{50}{\sqrt{36}} = 8.3$$

$$P(\bar{x} \leq 980) = P(z \leq \frac{980 - 1000}{8.3}) = P(z \leq -2.41) = 0.0080$$



ESTIMADORES PONTUAIS




Propriedades

- Tendência
- Variância Mínima
- Eficiência
- Consistência
- Suficiência
- Robustez

Estimador não tendencioso

Uma estatística $\hat{\theta}$ é um estimador não tendencioso do parâmetro θ se e só se

$$E[\hat{\theta}] = \theta$$





Tendência

Exemplo 1

Mostre que X/n é um estimador não tendencioso do parâmetro p da distribuição binomial.

$$E[X] = np$$

$$E\left[\frac{X}{n}\right] = \frac{1}{n} E[X] = p$$



Tendência

Exemplo 2

Sejam uma amostra aleatória de uma população dada por

$$f(x) = \begin{cases} e^{-(x-\delta)} & x > \delta \\ 0 & \text{outros valores} \end{cases}$$

Mostre que \bar{X} é um estimador tendencioso de δ .

$$\mu = E[X] = \int_{\delta}^{\infty} x e^{-(x-\delta)} dx = -x e^{-(x-\delta)} \Big|_{\delta}^{\infty} - \int_{\delta}^{\infty} -e^{-(x-\delta)} dx = 1 + \delta$$


$$E[\bar{X}] = 1 + \delta \neq \delta$$

$$E[\bar{X} - 1] = \delta \Rightarrow \bar{X} - 1 \quad \begin{array}{l} \text{estimador não} \\ \text{tendencioso de } \delta \end{array}$$

Eficiência

Se $\hat{\theta}_1$ e $\hat{\theta}_2$ são dois estimadores não tendenciosos do parâmetro θ de uma dada população e se a variância de $\hat{\theta}_1$ é menor que a variância de $\hat{\theta}_2$, diz-se que $\hat{\theta}_1$ é relativamente mais eficiente que $\hat{\theta}_2$.


$$\frac{Var[\hat{\theta}_1]}{Var[\hat{\theta}_2]}$$



Erro Quadrático Médio

Se $\hat{\theta}$ não é um estimador não tendencioso de um dado parâmetro θ , as comparações devem ser feitas com base no Erro Quadrático Médio em vez da variância.

$$E\left[\left(\hat{\theta} - \theta\right)^2\right] = \text{Var}\left[\hat{\theta}\right] + \left[E\left[\hat{\theta}\right] - \theta\right]^2$$





Erro Quadrático Médio

$Var[\hat{\theta}]$ pequena

$$E[\hat{\theta}] = \theta$$



Exacto e preciso...

$Var[\hat{\theta}]$ grande




Exacto e pouco preciso...

$$E[\hat{\theta}] \neq \theta$$



Pouco exacto e preciso...



Pouco exacto e pouco preciso...

Consistência

- A estatística $\hat{\theta}$ é um estimador consistente do parâmetro θ se e só se para cada $c > 0$

$$\lim_{n \rightarrow \infty} P\left(\left|\hat{\theta} - \theta\right| < c\right) = 1$$

A consistência é uma propriedade assintótica.

- Se $\hat{\theta}$ é um estimador não tendencioso de um dado parâmetro θ e $Var[\hat{\theta}] \rightarrow 0$ à medida que $n \rightarrow \infty$, então $\hat{\theta}$ é um estimador consistente de θ .



Consistência

Exemplo 3

Mostre que a média aritmética \bar{x} é um estimador consistente da média μ .

$$\text{Var}[\bar{x}] = \frac{\sigma^2}{n} \rightarrow 0 \quad n \rightarrow \infty$$

Suficiência

- Um estimador é suficiente se usa toda a informação da amostra relevante para a estimação de θ ; isto é, se todo o conhecimento acerca de θ que pode ser ganho a partir dos valores amostrais individuais e da sua ordem, pode também ser ganho pelo valor de $\hat{\theta}$ por si só.
- A estatística $\hat{\theta}$ é um estimador suficiente do parâmetro θ se e só se para cada valor de $\hat{\theta}$ a probabilidade condicional da amostra aleatória X_1, X_2, \dots, X_n dado $\hat{\theta} = \hat{\theta}_1$ é independente de θ .



Consistência e Suficiência

$$\text{Var}[\hat{\theta}]$$

$$\text{Var}[\hat{\theta}] \rightarrow 0$$

Consistência



$$n \rightarrow \infty$$



Suficiência



Suficiente...



Não suficiente...



Máxima Verosimilhança

- Os estimadores gerados por este método são, em geral, suficientes, não tendenciosos e assintoticamente de variância mínima.
- Com base nos valores observados na amostra aleatória, é escolhido um valor para a estimativa que maximiza a probabilidade de obter aqueles dados.



Máxima Verosimilhança

Exemplo 4

Uma urna contém um grande número de bolas vermelhas e negras, na proporção de 3:1. Contudo, não se sabe qual das cores está presente em maioria, se a vermelha se a negra.

Para o efeito, uma amostra de 3 bolas é retirada dessa urna. Assim, os resultados possíveis são:

$$(V,N): (3,0); (2,1); (1,2); (0,3).$$

- Para um grande número de bolas dentro da urna, as probabilidades podem ser descritas por uma distribuição binomial.
- No entanto, as probabilidades associadas a cada um dos eventos dependem de qual a cor presente em maioria.



Máxima Verosimilhança

Exemplo 4

Nº de bolas vermelhas	0	1	2	3
$(V,N)=(3,1) \quad p = 3/4$	1/64	9/64	27/64	27/64
$(V,N)=(1,3) \quad p = 1/4$	27/64	27/64	9/64	1/64

Tendo saído o resultado: (2,1)

Qual cor é que será mais provável estar em maioria?

Vermelha

Tendo saído o resultado: (0,3)

Qual cor é que será mais provável estar em maioria?

Negra



Função de Máxima Verosimilhança

- No caso discreto, uma amostra aleatória de n observações, x_1, x_2, \dots, x_n com uma função de probabilidade dependente de um parâmetro θ então a probabilidade de observar estes valores independentes é dada por,

$$P(x_1, x_2, \dots, x_n) = P(x_1)P(x_2) \dots P(x_n) = f(x_1, x_2, \dots, x_n; \theta)$$

que corresponde à distribuição de probabilidade conjunta das variáveis aleatórias no ponto amostral (x_1, x_2, \dots, x_n)



Função de Máxima Verosimilhança

Se x_1, x_2, \dots, x_n são os valores de uma amostra aleatória de uma população com parâmetro θ , a função de verosimilhança é dada por,

$$L(\theta) = f(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

para valores de θ no domínio dado.

$f(x_1, x_2, \dots, x_n; \theta)$ é o valor da função de probabilidade conjunta ou da função de densidade conjunta das variáveis aleatórias x_1, x_2, \dots, x_n observadas.



Função de Máxima Verosimilhança

Exemplo 5

Considere uma variável aleatória de Bernoulli. A função de probabilidade é dada por

$$f(x; p) = \begin{cases} p^x (1-p)^{1-x} & x = 0, 1 \\ 0 & \text{outros valores} \end{cases}$$

onde p é o parâmetro a ser estimado.

$$\begin{aligned} L(p) &= p^{x_1} (1-p)^{1-x_1} p^{x_2} (1-p)^{1-x_2} \dots p^{x_n} (1-p)^{1-x_n} = \\ &= \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i} \end{aligned}$$

O máximo de $L(p)$ é também o máximo de $\ln L(p)$



Função de Máxima Verosimilhança

Exemplo 5

$$\ln L(p) = \left(\sum_{i=1}^n x_i \right) \ln p + \left(n - \sum_{i=1}^n x_i \right) \ln (1 - p)$$

$$\frac{d \ln L(p)}{dp} = \frac{\sum_{i=1}^n x_i}{p} - \frac{\left(n - \sum_{i=1}^n x_i \right)}{1 - p}$$

$$\hat{p} = \frac{\sum_{i=1}^n x_i}{n}$$



Função de Máxima Verosimilhança

Exemplo 6

Considere uma variável aleatória exponencial.

Calcule o estimador de máxima verosimilhança para o parâmetro θ com base numa amostra de tamanho n . Considere, em seguida, uma amostra de dez valores respeitantes ao tempo de vida (em horas) de um componente eléctrico (8.2, 40.5, 3.9, 7.7, 7.1, 3.3, 4.3, 25.4, 5.2, 1.0). Estime o valor do parâmetro θ com base nestes 10 valores.

$$L(\theta) = f(x_1)f(x_2)...f(x_n) = \prod_{i=1}^n \frac{1}{\theta} e^{-\frac{x_i}{\theta}} = \left(\frac{1}{\theta}\right)^n e^{-\frac{1}{\theta} \sum_{i=1}^n x_i}$$



Função de Máxima Verosimilhança


Exemplo 6

$$\ln L(\theta) = -n \ln \theta - \frac{1}{\theta} \sum_{i=1}^n x_i$$

$$\frac{d \ln L(\theta)}{d\theta} = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n x_i = 0$$

$$\hat{\theta} = \frac{\sum_{i=1}^n x_i}{n} = \bar{x}$$

$$\hat{\theta} = \bar{x} = 10.66$$





Função de Máxima Verosimilhança

Exemplo 7

Sejam x_1, x_2, \dots, x_n os valores de uma amostra de uma distribuição uniforme, com parâmetros $\alpha = 0, \beta = a$.

Encontre o estimador de máxima verosimilhança para a .

$$f(x; a) = \frac{1}{a} \quad 0 < x < a$$

$$L(a) = \prod_{i=1}^n f(x_i; a) = \left(\frac{1}{a}\right)^n$$

$$\ln L(a) = -n \ln a$$


$$\frac{d \ln L(a)}{da} = -\frac{n}{a} = 0$$



Função de Máxima Verosimilhança

Exemplo 7

- O valor da função de verosimilhança cresce à medida que a decresce.
- Contudo, para qualquer valor observado, $0 \leq x_i \leq a$ logo a não pode ser menor que qualquer valor da amostra.
- Assim, a função atinge o seu máximo quando a é igual ao maior dos valores da amostra.



$$\hat{a} = \max(x_i)$$