



Estimação Espectral Moderna (M. E. M.)



- Teorema da projecção (princípio da ortogonalidade)
 - Métodos clássicos truncam a sequência de autocorrelação, que pode em certas condições ser extrapolada para $m > N$.
 - **Problema:** Como estimar uma v. a. X_N a partir de N v. a. X_0, X_1, \dots, X_{N-1} , de modo que seja mínimo o valor quadrático médio do erro.

$$\hat{X}_N = a_1 X_{N-1} + a_2 X_{N-2} + \dots + a_N X_0$$

$$MMSE = E\left\{\left(X_N - a_1 X_{N-1} - a_2 X_{N-2} - \dots - a_N X_0\right)^2\right\}$$

Pretende-se então determinar as N constantes (a_k) que minimizam MMSE

$$MMSE = E\left\{\left(X_N - \sum_{i=1}^N a_i X_{N-i}\right)^2\right\} = E\left\{\left(X_N - \sum_{\substack{i=1 \\ i \neq k}}^N a_i X_{N-i} - a_k X_{N-k}\right)^2\right\} = E\left\{\left(A - a_k X_{N-k}\right)^2\right\}$$

Minimizando em ordem a a_k

$$\begin{aligned} \frac{\partial(MMSE)}{\partial a_k} &= E\left\{-2X_{N-k}A + 2a_k X_{N-k}^2\right\} = -2E\left\{(A - a_k X_{N-k})X_{N-k}\right\} \\ &= -2E\left\{(X_N - \hat{X}_N)X_{N-k}\right\} \end{aligned}$$




Estimação Espectral Moderna (M. E. M.)



- A solução do problema é então:

- Os a_k satisfazem $E\{(X_N - \hat{X}_N)X_{N-k}\} = 0 \quad k = 1, 2, \dots, N$
- Duas v. a. X e Y são ortogonais se $E\{X.Y\} = 0$
- Os a_k são tais que o erro é ortogonal aos dados. Isto é o enunciado do teorema da projecção ou principio da ortogonalidade.





Estimação Espectral Moderna (M. E. M.)



– Se as v. a. correspondem a um P. E. estacionário $\phi_{xx}(N, N-k) = \phi_{xx}(-k)$

$$E\left\{\left(X_N - \sum_{i=1}^N a_i X_{N-i}\right) X_{N-k}\right\} = 0 \quad k = 1 \dots N \quad \longrightarrow \quad \phi_{xx}(k) = \sum_{i=1}^N a_i \phi_{xx}(|k-i|)$$

$$\begin{cases} a_1 \phi(0) + a_2 \phi(1) + \dots + a_N \phi(N-1) = \phi(1) \\ \dots \\ a_1 \phi(N-1) + a_2 \phi(N-2) + \dots + a_N \phi(0) = \phi(N) \end{cases}$$

**Equações de Yule-Walker
ou equações normais**

$$\begin{bmatrix} \phi(0) & \phi(1) & \dots & \phi(N-1) \\ \dots & \dots & \dots & \dots \\ \phi(N-1) & \phi(N-2) & \dots & \phi(0) \end{bmatrix} \begin{bmatrix} a_1 \\ \dots \\ a_N \end{bmatrix} = \begin{bmatrix} \phi_1 \\ \dots \\ \phi_N \end{bmatrix}$$


– O erro mínimo é

$$\begin{aligned} MMSE_{\min} &= E\left\{\left(X_N - \hat{X}_N\right)^2\right\} = E\left\{\left(X_N - \hat{X}_N\right)\left(X_N - \hat{X}_N\right)\right\} \\ &= E\left\{X_N \cdot \left(X_N - \hat{X}_N\right)\right\} - \underbrace{E\left\{\hat{X}_N \cdot \left(X_N - \hat{X}_N\right)\right\}}_{=0; \text{ erro } \perp \text{ aos dados}} = \phi_{xx}(0) - \sum_{i=1}^N a_i \phi_{xx}(i) \end{aligned}$$



- Modelos para processos estocásticos

- Geralmente a sequência $x[n]$ é modelada como sendo a saída de um sistema LTI causal cuja entrada é uma sequência ruído branco $w[n]$ de média nula e variância σ_w^2



- Equação de diferenças
$$x[n] = \sum_{k=1}^N a_k x[n-k] + \sum_{k=0}^q b_k w[n-k]$$
- Relação entre espectros
$$P_{xx}(\Omega) = |H(\Omega)|^2 P_{ww}(\Omega) = \sigma_w^2 \left| \frac{B(\Omega)}{A(\Omega)} \right|^2$$
- Classificação dos P. E.
 - Autoregressive Moving Average (ARMA) process se N e q ambos $\neq 0$
 - Moving Average (MA) process se $N=0$ e $q \neq 0 \Rightarrow A(\Omega)=1$
 - Autoregressive (AR) process se $q=0$ e $N \neq 0 \Rightarrow B(\Omega)=1$



- Método de Estimação Espectral da Entropia Máxima (MEM)

- Conhecendo $M+1$ valores de $\phi_{xx}(m)$: $\phi_{xx}(-M) \dots \phi_{xx}(0), \dots, \phi_{xx}(M)$, em vez de fazer $\phi_{xx}(m)=0$ para $|m|>M$, determinamos o preditor linear de ordem M resolvendo os a_k das equações:

$$\begin{bmatrix} \phi(0) & \phi(1) & \dots & \phi(M-1) \\ \dots & \dots & \dots & \dots \\ \phi(M-1) & \phi(M-2) & \dots & \phi(0) \end{bmatrix} \begin{bmatrix} a_1 \\ \dots \\ a_M \end{bmatrix} = \begin{bmatrix} \phi_1 \\ \dots \\ \phi_M \end{bmatrix}$$

- Se o PE é autorregressivo de ordem M e estimamos $x[n]$ como $\hat{x}[n] = \sum_{k=1}^M a_k x[n-k]$

Então o erro de predição é ruído branco, ou seja a predição é a melhor possível

$$x[n] - \hat{x}[n] = w(n) \quad x[n] = \sum_{k=1}^M a_k x[n-k] + w(n)$$

$$\sigma_w^2 = E\{(x[n] - \hat{x}[n])^2\} = MMSE = \phi_{xx}(0) - \sum_{k=1}^M a_k \phi_{xx}(k)$$

No caso de PE autorregressivos temos

$$P_{MEM}(\Omega) = \frac{MMSE}{\left| 1 - \sum_{k=1}^M a_k e^{-jk\Omega} \right|^2}$$



- Algumas notas sobre o estimador de entropia máxima

- A informação existente numa sequência é definida em termos da entropia de Shannon. Para um PE Gaussiano a taxa de entropia (entropia por amostra) é proporsional a:

$$H \propto \int_{-\pi}^{\pi} \log P(\Omega) d\Omega$$

A ideia é escolher $P(\Omega)$ de modo a maximizar H mas com a restrição de

Deste modo $\frac{1}{2\pi} \int_{-\pi}^{\pi} P(\Omega) e^{-jm\Omega} d\Omega = \phi_{xx}(m) \quad |m| = 0, 1, 2, \dots, M$
os valores de autocorrelação correspondentes ao espectro de máxima entropia coincidem com os valores dados ($|m| < M$), sendo os valores de autocorrelação para fora desta gama estimados pelo estimador linear de ordem M . Deste modo a extrapolação da sequência de autocorrelação não adiciona nenhuma informação ao processo ou seja a entropia (incerteza sobre o processo) é mantida e é máxima, daí a designação de método da entropia máxima.



- Problemas

- O processo pode ser MA ou ARMA.
- Mesmo que seja AR não se conhece a ordem

- Algumas pistas

- Se houver fundamento para supor que o processo é AR (p. e. fala) nunca se deverá utilizar um método clássico. A autocorrelação é infinita e os métodos clássicos truncam a autocorrelação.
- Se houver fundamento para supor que se trata de um processo MA de ordem N a autocorrelação é finita e de comprimento N. Os métodos clássicos serão de aplicar.

- Resumo do método da entropia máxima

- Calcular a seq. de autocorrelação $\phi_{xx}(m)$ (com base na realização do processo) para $|m| < M$
- Extrapolar a sequência de autocorrelação para $|m| > M$ através de

$$\phi_{xx}(m) = \sum_{i=1}^M a_i \phi_{xx}(m-i) \quad m = M+1, \dots, \infty$$



Estimação Espectral Moderna (M. E. M.)



- **Exemplo:** Considere o segmento de um sinal de potência de comprimento $N=5$ como sendo $x[n]=\{0, 1, 0, -1, 0\}$.

- Obtenha uma estimativa dos valores da autocorrelação $C_{xx}(m)$ para $-4 \leq m \leq 4$
- Determine o preditor linear de ordem 4 que minimiza o erro quadrático médio entre a estimativa do sinal e o seu verdadeiro valor. Calcule a estimativa de $x[5]$, $x[6]$, $x[7]$, e $x[8]$.
- Calcule o erro do preditor
- Determine o espectro de máxima entropia

a)

$$C_{xx}(m) = \frac{1}{5} \sum_{n=0}^{4-|m|} x[n]x[n+m] = \begin{cases} 2/5 & m = 0 \\ 0 & |m| = 1 \\ -1/5 & |m| = 2 \\ 0 & |m| = 3 \\ 0 & |m| = 4 \end{cases}$$

b) Equações de Yule-Walker

$$\begin{bmatrix} 2 & 0 & -1 & 0 \\ 0 & 2 & 0 & -1 \\ -1 & 0 & 2 & 0 \\ 0 & -1 & 0 & 2 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ a_3 \\ a_4 \end{bmatrix} = \begin{bmatrix} 0 \\ -1 \\ 0 \\ 0 \end{bmatrix} \Rightarrow \begin{matrix} a_1 = a_3 = 0 \\ a_2 = 2a_4 = -\frac{2}{3} \end{matrix} \Rightarrow \hat{x}[n] = -\frac{2}{3}x[n-2] - \frac{1}{3}x[n-4]$$

$$\hat{x}[5] = \frac{1}{3} \quad \hat{x}[6] = 0 \quad \hat{x}[7] = \frac{1}{9} \quad \hat{x}[8] = 0$$



Estimação Espectral Moderna (M. E. M.)



c) O erro do preditor é dado por $MMSE = \phi_{xx}(0) - \sum_{k=1}^4 a_k \phi_{xx}(k) = \frac{4}{15}$

d) O espectro de entropia máxima é dado por $P_{MEM}(\Omega) = \frac{MMSE}{\left|1 - \sum_{k=1}^M a_k e^{-jk\Omega}\right|^2}$

— Problemas

- 1) Mostre que o MMSE do preditor linear de ordem N é dado por $MMSE = \frac{\Delta_{N+1}}{\Delta_N}$ em que Δ_N é o determinante da matriz de autocorrelação de ordem N
- 2) Mostre que os parâmetros de um processo autorregressivo de ordem M são os coeficientes de predição linear do processo.
- 3) Mostre que o preditor linear de ordem N de um Processo AR de ordem M ($M < N$) tem coeficientes a_k dados por

$$\begin{cases} a_k = c_k, & k = 1, 2, \dots, M \\ a_k = 0, & k = M + 1, M + 2, \dots, N \end{cases}$$

Em que c_k são os parâmetros autoregressivos.

- 4) Mostre que num processo autoregressivo de ordem M se tem

$$\phi_{xx}(m) = \sum_{k=1}^M a_k \phi_{xx}(m-k)$$



- Problemas (cont)

- 5) Relacione numericamente os resultados dos problemas 1, 3 e 5. Considere um processo AR de 1ª ordem de que se conhecem $\varphi(0)=2$ e $\varphi(1)=1$.
 - a) Determine o preditor linear de ordem 1.
 - b) Determine $\varphi(2)$
 - c) Determine o preditor linear de ordem 2 e verifique o resultado do problema 3.
 - d) Calcule os erros de predição dos preditores de 1ª e 2ª ordem e comente.
- 6) Resolva o projecto 1 do capítulo 6 (parte de estimação espectral moderna) do livro de exercícios com Matlab.