

b) O periodograma é a T.F. da estrutura da autocorrelação (imutável).

$$E\{I_N(\omega)\} = ?$$

$$I_N(\omega) = \sum_{n=-\infty}^{+\infty} (x_n[m]) e^{-j\omega m} \quad (\text{Definição de DTFT})$$

$$E\{I_N(\omega)\} = \sum_{n=-\infty}^{+\infty} E\{(x_n[m])\} e^{-j\omega m}$$

$$E\{(x_n[m])\} = \underbrace{\frac{N-|m|}{N}} \phi_{xx}[m] \quad (\text{almeia autovar})$$

$$\text{Então } E\{I_N(\omega)\} = \sum_{n=-\infty}^{+\infty} \frac{N-|m|}{N} \phi_{xx}[m] e^{-j\omega m}$$

Nos métodos clássicos $\phi_{xx}[m] = \phi_{xx}[-m]$ e $\phi_{xx}[m] = 0$ $\forall m > N-1$

Então podemos fixar os valores nulos do sumatório e

$$E\{I_N(\omega)\} = \sum_{n=-(N-1)}^{N-1} \frac{N-|m|}{N} \phi_{xx}[m] e^{-j\omega m} \quad \boxed{\text{C. P. d.}}$$

c) A propriedade da convolução da T.F. diz que:

$$\begin{aligned} x[n] &\longleftrightarrow X(\omega) \\ x[n] \cdot y[n] &\longleftrightarrow X(\omega) * Y(\omega) \end{aligned}$$

$$\text{Como } E\{I_N(\omega)\} = \sum_{n=-\infty}^{+\infty} \frac{N-|m|}{N} \phi_{xx}[m] e^{-j\omega m}$$

$$\text{Então pelo prop. conv. : } \text{D.T.F.T.}\{x[n] \cdot y[n]\}$$

$$E\{I_N(\omega)\} = X(\omega) * Y(\omega) = P_{xx}(\omega) * \frac{1}{N} \left(\frac{\sin \frac{N}{2} \omega}{\sin \omega/2} \right)^2$$

D.T.F.T da janela triangular

d) O método de Bartlett surge da necessidade de diminuir a variância do periodograma. De facto esperava-se que o periodograma por ser a T.F. da seq. estrutural (Constante) da sequência de autocorrelação fosse um estimador consistente por ser a T.F. de um estimador também ele consistente. Mas de facto não é isso que acontece e a variância do periodograma não dec. q. o aumento de amostra. Sabe-se da estatística que a soma de K variáveis aleatórias independentes e idênticas distribuídas (i.i.d.) gera uma v.a. cuja variância é $1 \times$ a var de cada uma das v.a. somadas. Por esta razão Bartlett sugeriu a média de periodogramas como uma forma de diminuição da variância do periodograma. O método consiste então em dividir os dados (N) em K segmentos de M dados. Fazer o periodograma de cada segmento e a média dos K periodogramas. O método reduz a resolução espectral de $K = N/M$ uma vez que o periodograma de N pontos tem também N pontos na frequência, logo cada periodograma de M pontos terá $M = N/K$ pontos na frequência. No entanto como o periodograma pode ser calculado via FFT por $P_N(\omega) = |X(\omega)|^2 / N$ podemos calcular uma FFT de N pontos para o sinal de M pontos mantendo assim a resolução espectral. Isto é conseguido juntando $N-M$ zeros aos M pontos do sinal. A inclusão de zeros não traz mais informação e por isso o aumento de resolução espectral por esta via não é efectiva ou seja não melhora qualitativamente o sinal.

e) $\{x(n)\}$ tem média nula e variância σ_x^2

$$\text{var} \{ |X(k)| \} = E \{ |X(k)|^2 \} - E \{ |X(k)| \}^2 \quad \text{por definição.}$$

$$X(k) = \frac{1}{N} \sum_{n=0}^{N-1} x(n) e^{-j k n \frac{2\pi}{N}} \Rightarrow E \{ |X(k)| \} = \frac{1}{N} \sum_{n=0}^{N-1} E \{ x(n) \} e^{-j k n \frac{2\pi}{N}} = 0$$

$$\text{Então } \text{var} \{ |X(k)| \} = E \{ |X(k)|^2 \} = E \{ X(k) \cdot X^*(k) \}$$

$$= E \left\{ \frac{1}{N} \sum_{n_1=0}^{N-1} x(n_1) e^{-j k n_1 \frac{2\pi}{N}} \frac{1}{N} \sum_{n_2=0}^{N-1} x(n_2) e^{j k n_2 \frac{2\pi}{N}} \right\}$$

$$= \frac{1}{N^2} \sum_{n_1=0}^{N-1} \sum_{n_2=0}^{N-1} E \{ x(n_1) x(n_2) \} e^{-j k \frac{2\pi}{N} (n_1 - n_2)}$$

$$\text{var}\{x(n)\} = \frac{1}{N^2} \sum_{n=0}^{N-1} \sum_{m=0}^{N-1} e^{j2\pi n(m-n)/N} = \frac{\sigma_u^2}{N}$$

f) Para um sinal de média nula a sua potência seria

$$E\{u^2(n)\} = \sigma_u^2 + \sigma_u^2 = \sigma_u^2$$

No domínio das frequências temos que a densidade espectral é $|X(u)|^2$. A potência seria a densidade espectral de todo somado em todas as k componentes ou seja

$$P = \sum_k E\{|X(u)|^2\} = N \cdot \frac{\sigma_u^2}{N} = \sigma_u^2 = \text{ao calculado}$$

No domínio do tempo

g) $\frac{u(n)}{H(z)} \rightarrow y(n)$ $H(z) = \frac{1}{1 - \sum_{k=1}^N a_k z^{-k}}$

$$H(z) = \frac{Y(z)}{X(z)} = \frac{1}{1 - \sum_{k=1}^N a_k z^{-k}}$$

$$\Rightarrow Y(z) \left[1 - \sum_{k=1}^N a_k z^{-k} \right] = X(z)$$

Aplicando a T.F. inversa a ambos os membros da eq. (lembra)

$$y(n) = \sum_{k=1}^N a_k y(n-k) + \underbrace{u(n)}_{\text{ruído branco}}$$

ou seja $y(n) = \sum_{k=1}^N a_k y(n-k)$

$n-m = (n-k) + (k-m)$
 $k-m = m-k$
 Then

$$y(n) \cdot y(n-m) = \sum_{k=1}^N a_k y(n-k) y(n-m)$$

Aplicando F.T.

$$\phi_{yy}(m) = \phi_{yy}(n) = \sum_{k=1}^N a_k \phi_{yy}(n-k)$$

↳ causal



(a) _____ Unidade Curricular _____

Curso _____ Docente _____

ALUNO (b) _____ em ____/____/____

h) Com 4 amostras podemos calcular $(4-1) \times 2 + 1 = 7$ valores de autocorrelação

$$C_{xx}[-3], C_{xx}[-2], C_{xx}[-1], C_{xx}[0], C_{xx}[1], C_{xx}[2], C_{xx}[3]$$

Usando a eq. obtida nas alíneas anteriores:

$$\phi_{xx}[m] = \sum_{k=1}^N a_k \phi_{xx}[m-k] \quad \text{Podemos escrever um}$$

sistema de 3 eq. a 3 incógnitas (eq. de Yule-Walker)

$$\begin{bmatrix} \phi_{xx}[0] & \phi_{xx}[1] & \phi_{xx}[2] \\ \phi_{xx}[1] & \phi_{xx}[0] & \phi_{xx}[1] \\ \phi_{xx}[2] & \phi_{xx}[1] & \phi_{xx}[0] \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = \begin{bmatrix} \phi_{xx}[1] \\ \phi_{xx}[2] \\ \phi_{xx}[3] \end{bmatrix}$$

Os a_k 's determinados pela solução deste sistema são os que minimizam o erro quadrático médio, ou seja:

$$MSE = E \{ (x_n - \hat{x}_n)^2 \} = E \{ (x_n - \hat{x}_n) (x_n - \hat{x}_n) \}$$

$$= E \{ x_n (x_n - \hat{x}_n) \} - E \{ \underbrace{\hat{x}_n}_{\text{dado erro}} (x_n - \hat{x}_n) \}$$

Como o erro é ortogonal aos dados e então,

$$MSE = E \{ x_n x_n - x_n \hat{x}_n \} = E \{ x_n x_n - x_n \sum_{k=1}^N a_k x_{n-k} \}$$

$$= E \{ x_n^2 \} - \sum_{k=1}^N a_k \phi_{xx}(k)$$

$$= \phi_{xx}[0] - \sum_{k=1}^N a_k \phi_{xx}(k)$$



Universidade do Minho

(a) _____ Unidade Curricular _____
 Curso Teste 2 2020-2021 Docente _____
 ALUNO (b) PIRETI em 1/1

1.

a) Um estimador é consistente se quer a sua polarização quer a sua variância tenderem para zero quando se vai tendo mais conhecimento sobre o processo ($N \rightarrow \infty$)

No caso concreto a variância é proporcional a $\frac{1}{N}$ logo

$\lim_{N \rightarrow \infty} \text{var}\{\hat{c}_{kk}(m)\} = 0$, o que significa que a

medida que se vai aumentando o n.º de dados a variância vai diminuindo. É preciso que se verifique o mesmo para a polarização para que o ~~est~~ estimador $\hat{c}_{kk}(m)$ seja consistente.

$$B_{\hat{c}_{kk}} = \hat{c}_{kk}(m) - E\{\hat{c}_{kk}(m)\}$$

$$E\{\hat{c}_{kk}(m)\} = \frac{1}{N} \sum_{n=0}^{N-1} E\{x(n)x(n+m)\} = \frac{N-|m|-1}{N} \hat{c}_{kk}(m)$$

$$B_{\hat{c}_{kk}} = \hat{c}_{kk}(m) - \frac{N-|m|-1}{N} \hat{c}_{kk}(m) = \hat{c}_{kk}(m) \left(1 - \frac{N-|m|-1}{N}\right) = \frac{|m|}{N} \hat{c}_{kk}(m)$$

$\lim_{N \rightarrow \infty} B_{\hat{c}_{kk}} = 0 \Rightarrow$ o estimador $\hat{c}_{kk}(m)$ é consistente.

$$2. \quad \Delta \tau(u) \rightarrow u_s, \hat{v}_s^2 \quad e \tau(u) \rightarrow u_e, \hat{v}_e^2$$

$$a) \quad \eta \tau(u) = \Delta \tau(u) + e \tau(u)$$

$$\begin{aligned} \phi_{\eta\eta}(\omega) &= E \{ \eta \tau(u) \eta \tau(u+m) \} = E \{ (\Delta \tau(u) + e \tau(u)) (\Delta \tau(u+m) + e \tau(u+m)) \} \\ &= E \{ \Delta \tau(u) \Delta \tau(u+m) + \Delta \tau(u) e \tau(u+m) + e \tau(u) \Delta \tau(u+m) + e \tau(u) e \tau(u+m) \} \end{aligned}$$

$$\phi_{\eta\eta}(\omega) = \phi_{\Delta\Delta}(\omega) + 2 \phi_{\Delta e}(\omega) + \phi_{ee}(\omega)$$

$$\text{se } \Delta \tau(u) = A \cos(\omega_0 u + \varphi) \text{ então } \boxed{u_s = 0}$$

$$\phi_{\Delta\Delta}(\omega) = \chi_{\Delta\Delta}(\omega) = E \{ \Delta \tau(u) \Delta \tau(u+m) \} = A^2 E \{ \cos(\omega_0 u + \varphi) \cos(\omega_0(u+m) + \varphi) \}$$

$$\cos(a+b) = \cos a \cos b - \sin a \sin b$$

$$\cos(a-b) = \cos a \cos b + \sin a \sin b$$

$$2 \cos a \cos b = \cos(a+b) + \cos(a-b) \Rightarrow \cos a \cos b = \frac{\cos(a+b) + \cos(a-b)}{2}$$

$$\phi_{\Delta\Delta}(\omega) = \frac{A^2}{2} E \{ \cos(2\omega_0 u + \omega_0 m + 2\varphi) + \cos(\omega_0 m) \}$$


$$= \frac{A^2}{2} \cos(\omega_0 m) \quad \text{Substituindo este resultado}$$


em \neq frames c/

$$\phi_{\eta\eta}(\omega) = \frac{A^2}{2} \cos(\omega_0 m) + 2 \cancel{u_s m_e} + \hat{v}_e^2 \delta(\omega) + m_e^2 \text{ c.g.}$$

$$b) \quad P_{\eta\eta}(\omega) = DT \{ \phi_{\eta\eta}(\omega) \}$$

$$= \frac{A^2 \pi}{2} (\delta(\Omega - \omega_0) + \delta(\Omega + \omega_0)) + \hat{v}_e^2 + 2 \hat{v}_e m_e^2 \delta(\omega)$$





$$H(n) = \frac{p_{ss}(n)}{p_{ss}(n) + p_{ee}(n)} = \frac{\sigma_s^2}{\sigma_s^2 + \sigma_e^2 + u_e^2}$$

↑
estacionária de

$$h(n) = \mathcal{I} \mathcal{D} \mathcal{T} \mathcal{F} \mathcal{T} \left\{ H(n) \right\} = \frac{\sigma_s^2}{\sigma_s^2 + \sigma_e^2 + u_e^2} \mathcal{J}(n)$$

$$\begin{aligned} d) \mathcal{J}(n) &= u_n + (x(n) - u_n) * h(n) \\ &= u_n + (x(n) - u_n) \frac{\sigma_s^2}{\sigma_s^2 + \sigma_e^2 + u_e^2} \end{aligned}$$

Como $u_n = u_s + u_e$ e $u_s \rightarrow$ limpo

$$\boxed{\mathcal{J}(n) = u_e + (x(n) - u_e) \frac{\sigma_s^2}{\sigma_s^2 + \sigma_e^2 + u_e^2}}$$

É preciso estimar u_e e σ_s^2

u_e e σ_e^2 podem ser estimados no início do áudio quando ainda só há ruído.

$\sigma_s^2 = \hat{\sigma}_n^2 - \sigma_e^2$ e pode ser estimado online pela variação do sinal observado ($\hat{\sigma}_n^2$) e σ_e^2 estimado antes.